UNIVERSIDAD AUTONOMA DE LA CIUDAD DE MÉXICO

Viernes, 23 de Octubre del 2026

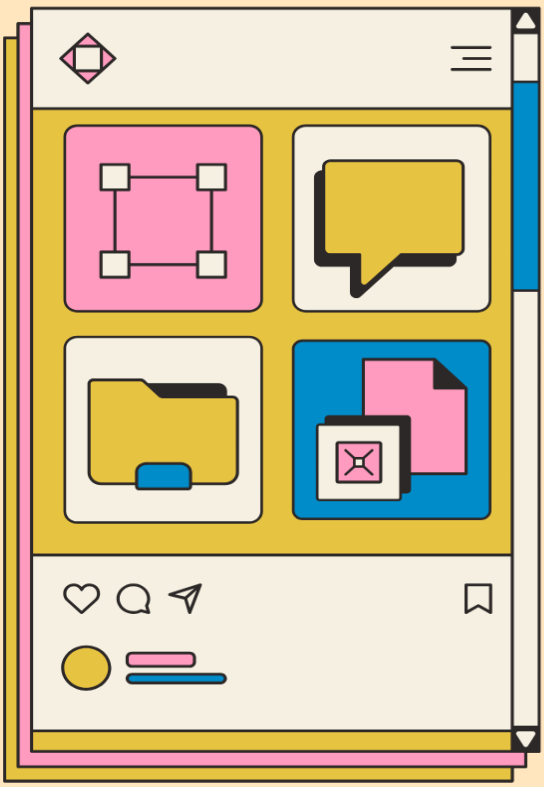
PROYECTO DE:

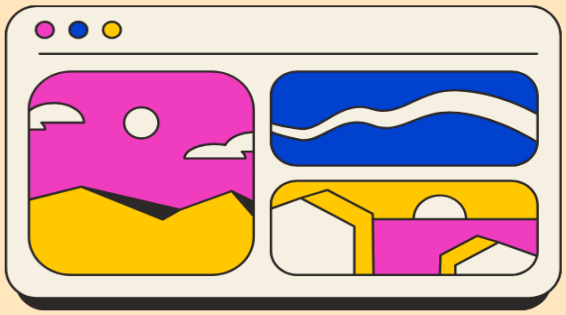
ANÁLISIS DE FRECUENCIA Y SEVERIDAD DE HECHOS DE TRÁNSITO EN LA CDMX

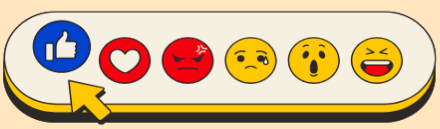
AVANCE02: LECTURA, PERFILAMIENTO Y PREPARACIÓN DE DATOS CON PYTHON

Equipo: A&C
Integrantes: Méndez Cabral Ángel David (23-003-1466)
Ruiz Moreno Citlalli Viviana (23-003-1162)
Grupo: 301
Semestre: 2026-2

Enlace de GitHub:
https://github.com/citlalliruiz31/Proyecto-sobre-Analisis-de-hechos-de-transito-de-la-CDMX/blob/main/Bitacora/Bitacora_AC.md







Índice

01 Resumen
02 Continuidad del proyecto y cambio de pregunta
03 Fuentes y contrato de lectura
04 Perfilamiento inicial
05 Hallazgos de calidad
06 Preparación y reglas
07 Validaciones y comparación
08 Análisis específico de fallecidos y unidades médicas
09 Alcances, limitaciones y próximos pasos
10 Referencias y evidencias

1. Resumen

Este avance documenta la lectura, delimitación, inspección, perfilamiento, preparación y validación de cuatro fuentes: SSC, C5, INEGI-ATUS y Kaggle. El análisis se restringe a registros de las 16 alcaldías de la Ciudad de México y a periodos a partir de 2018, según la cobertura efectiva de cada fuente. Las salidas examinadas muestran que varias repeticiones y discrepancias se conservan para revisión, en lugar de eliminarlas arbitrariamente.

La decisión de negocio es identificar alcaldías y horarios con mayor concentración de personas lesionadas y fallecidas para orientar la priorización de acciones preventivas. No se atribuyen causas a partir de asociaciones descriptivas.

2. Continuidad y cambio de pregunta

Pregunta del Avance 1

¿En qué alcaldías y horarios de la CDMX se concentra la mayor frecuencia de hechos de tránsito y en cuáles se observa mayor severidad (lesionados/fallecidos)?

Pregunta vigente, ajustada en el Avance 2

¿En qué alcaldías y franjas horarias de la CDMX se registra la mayor cantidad de personas lesionadas en hechos de tránsito, de acuerdo con los registros disponibles a partir de 2018?

Motivo del ajuste. Durante el perfilamiento y la limpieza se detectaron limitaciones de cobertura e interpretación de la variable de fallecidos en los registros usados para el análisis principal. Por ello se delimitó la pregunta a personas lesionadas, manteniendo los fallecimientos como información descriptiva secundaria y documentando sus cantidades y la disponibilidad del campo de unidad médica. Esta decisión evita presentar como comparable o exhaustiva una medida cuya suficiencia aún debe verificarse entre fuentes.

La pregunta revisada no implica que todos los datos de fallecidos sean nulos: distingue entre valores registrados, faltantes y cobertura suficiente para el uso analítico previsto.

3. Fuentes y contrato de lectura

Fuente	Cobertura observada / uso	Registros tras delimitación

SSC	2018–2023 fuente principal (tabla de hechos)	134,078
C5	2018–2024 contexto de incidentes	1,341,419
INEGI-ATUS	2018–2025 contraste estadístico	62,424
Kaggle ATUS	2018–2022 contexto histórico y de comparacion	43,217

Los CSV originales se conservaron separados de las salidas de etapa 1, 2 y 3. Los notebooks por fuente y el archivo funciones_calidad.py documentan las lecturas y las comprobaciones. No deben sumarse los registros de distintas fuentes: pueden representar unidades de observación y coberturas diferentes.

4. Perfilamiento inicial

Perfilar consiste en diagnosticar el contenido ANTES de aplicar reglas de limpieza, número de filas y columnas, tipos de lectura, ausencias, valores distintos, frecuencias, repeticiones y rangos de variables cuantitativas. La unidad de observación se analiza por tabla: en SSC, las tablas de personas y vehículos pueden contener varias filas relacionadas con un mismo folio, por lo que folio no siempre es una clave única.

Fuente / tabla	Filas	Hallazgo relevante
SSC: HechosTransito	134,078	218 folios utilizables repetidos; 7,288 folios SD/equivalentes
SSC: Personas por edad	158,076	3,498 repeticiones adicionales idénticas; revisión pendiente
C5	1,341,419	76,204 filas con discrepancias entre alcaldías reportadas
INEGI-ATUS	62,424	145 duplicados adicionales en 46 columnas; 3 fechas inválidas
Kaggle	43,217	38 duplicados adicionales; 76 filas en grupos duplicados

Para cada variable indispensable se distinguen los valores realmente ausentes de los ceros registrados. También se comprueban fechas, alcaldías y campos de personas lesionadas; las categorías repetidas o los folios compartidos no se interpretan automáticamente como errores.

5. Hallazgos de calidad

Señal	Evidencia	Efecto / decisión
SSC: folios SD	7,288 en HechosTransito	No utilizarlos como identificador único
SSC: edad	13,918 faltantes; 14 mayores a 120	Conservar valor original y crear edad validada
SSC: duplicados por edad	3,498 adicionales	Conservar y revisar granularidad
C5: alcaldía	76,204 discrepancias	Marcar para revisión; no reasignar sin fundamento
C5: hora	1,544 faltantes en creación	No inventar horas
INEGI: fechas	3 calendarios inválidos	Señalar sin suponer fecha correcta
Kaggle: duplicados	38 adicionales	Mantener evidencia y revisar

6. Preparación y reglas

Lo importante es distinguir entre dos reportes del mismo accidente y dos registros que representan personas o vehículos diferentes. Un folio repetido no es, por sí solo, motivo suficiente para eliminar una fila: primero verificamos la unidad de observación, la alcaldía y los campos relevantes; los registros retirados se conservan como evidencia en un CSV independiente.

Etapa 1 — Delimitación: filtrar fechas desde 2018 y las 16 alcaldías; exportar conservados y excluidos. Etapa 2 — Perfilamiento y validación: revisar tipos, faltantes, frecuencias, fechas, folios y duplicados sin eliminación automática. Etapa 3 — Preparación: crear columnas auxiliares normalizadas, conservar originales y registrar pendientes en bitácora.

Se trabaja sobre copias de los DataFrames y se preservan los archivos de origen. Las equivalencias de alcaldías se aplican solamente cuando están documentadas; los registros con conflicto se marcan. En SSC se conserva la edad original y se genera una versión validada; los duplicados potencialmente legítimos permanecen pendientes.

7. Validaciones y comparación

Fuente	Recibidas para delimitación	Conservadas	Excluidas
SSC hechos	134,079	134,078	1
C5	2,115,080	1,341,419	773,661
INEGI-ATUS	2,883,722	62,424	2,821,298
Kaggle	1,827,593	43,217	1,784,376

Las comprobaciones entregadas verifican conteos y conservación de filas entre etapas. En SSC, C5 y Kaggle, la etapa 3 reporta cero eliminaciones adicionales en los resúmenes consultados. En INEGI-ATUS se exportan 62,424 filas, sin eliminaciones, con tres fechas calendáricas inválidas señaladas. La permanencia de los registros observados no significa que estén listos para cualquier análisis.

8. Fallecidos y unidades médicas: nota de alcance

Indicador en SSC HechosTransito (2018–2023)	Resultado
Filas de hechos de tránsito	134,078
Registros con fallecidos > 0	2,458
Suma de personas fallecidas registradas	2,608
Registros sin número interpretable de fallecidos	0
Registros con lesionados > 0	132,176
Suma de personas lesionadas registradas	155,988
Registros sin número interpretable de lesionados	0

El campo unidad_medica_de_apoyo identifica apoyo médico consignado en el registro; por sí solo NO demuestra qué institución certificó o notificó una defunción. La siguiente tabla refleja las etiquetas del campo entre hechos con personas_fallecidas > 0; no debe interpretarse como un listado de unidades que certificaron fallecimientos.

Unidad médica de apoyo registrada	Hechos con fallecidos
CCO/ERUM	679
CCO/PC	444
CCO/CRUZ ROJA	333

CCO	239
CCO/SAMU	132
ERUM/CCO	79
ERUM	61
CCO/CRUM	60
CRUZ ROJA/CCO	43
CCO/SD	31
CCO/URGENCIAS BASICAS	27
PC	23

Nota metodológica: estos conteos son de registros de hechos, no de certificaciones de defunción; una fila puede contener más de una persona fallecida. Para afirmar la unidad que reportó el fallecimiento sería necesario otro campo o documentación oficial que lo acredite.

9. Alcances, limitaciones y próximos pasos

Los datos preparados permiten explorar la distribución geográfica y temporal de personas lesionadas, con atención a diferencias entre las fuentes y sus periodos. La comparación directa de totales entre SSC, C5 e INEGI requiere homologar definiciones, cobertura y granularidad, y controlar duplicidad entre fuentes.

Pendientes: confirmar la definición oficial de fallecidos y el papel de la unidad médica; resolver duplicados por edad y conflictos geográficos; fijar reglas finales de agregación de lesionados por evento y franja horaria; preparar el ETL y posteriormente la integración con PostgreSQL y Power BI.

10. Referencias y evidencias

• Proyecto Inteligencia de Negocios.zip — resultados/ y Notebooks/ (entrega del equipo A&C).

• SSC — Hechos de tránsito reportados por SSC, base ampliada, datos.cdmx.gob.mx.

• C5 — Incidentes viales C5, datos.cdmx.gob.mx.

• INEGI — Estadística de Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS).

• Kaggle — Accidentes viales en México 1997–2022, Guillermo Hernández.

• UACM — Guía del Avance 2: lectura, perfilamiento y preparación de datos con Python, semestre 2026-2.

Actualización metodológica: tratamiento de registros duplicados

Acuerdo posterior a la revisión docente. Esta sección modifica la decisión preliminar de conservar todas las repeticiones. Los registros crudos y los archivos de la Etapa 2 permanecen intactos. La eliminación se realizará únicamente sobre copias en la Etapa 3, después de verificar la unidad de observación y exportar los casos retirados.

1. Justificación y alcance

Un mismo hecho de tránsito puede generar reportes de dos unidades de atención. Por ello, pueden existir reportes redundantes. Sin embargo, dos filas con el mismo folio no son necesariamente duplicados: también pueden corresponder a personas lesionadas distintas, vehículos diferentes o actualizaciones. Se define una clave y un conjunto de campos comparables por tabla; solo se retiran filas cuya redundancia haya sido confirmada. No se duplican entre fuentes sin un proceso de vinculación validado.

2. Perfilamiento de duplicados en Etapa 2

La proporción se calcula como (filas repetidas adicionales detectadas / filas aptas de la Etapa 1) × 100. Son hallazgos de perfilamiento, NO cantidades eliminadas todavía.

Fuente / tabla	Filas aptas	Repeticiones adicionales	% de filas aptas
SSC · Hechos de tránsito	134,078	0	0.00 %
SSC · Personas por edad	158,076	3,498	2.21 %
SSC · Personas por sexo	144,043	0	0.00 %
SSC · Personas por tipo	107,794	0	0.00 %
SSC · Vehículos	215,078	0	0.00 %
C5 · 17 columnas originales	1,341,419	0	0.00 %
INEGI–ATUS · 46 columnas	62,424	145	0.23 %

Kaggle–ATUS · 45 columnas	43,217	38	0.09 %

Nota: los conteos anteriores provienen de las validaciones comunicadas durante el proyecto; deben contrastarse con los CSV de evidencia antes de ejecutar eliminaciones. La detección de 3,498 repeticiones en PersonasLyFporEdad requiere especial revisión: filas iguales podrían representar personas distintas si faltan identificadores individuales. Las cifras de 145 y 38 son independientes; INEGI y Kaggle pueden solaparse.

3. Regla operativa de la Etapa 3

1. Trabajar siempre con una copia de los archivos de Etapa 2 y conservar los datos crudos.
2. Definir unidad de observación y campos de comparación específicos para cada tabla; excluir columnas técnicas añadidas durante la limpieza.
3. Distinguir folios compartidos, registros idénticos y reportes redundantes confirmados. No eliminar automáticamente los folios SD.
4. Exportar un CSV con todas las filas propuestas para retiro, motivo, identificador del grupo y campos de comparación.
5. Eliminar de la copia únicamente las filas aprobadas, conservar un representante por grupo y exportar el CSV limpio.
6. Verificar: filas de entrada = filas conservadas + filas retiradas; ausencia de duplicados bajo la regla adoptada; integridad de los originales; y variación de los KPIs de lesionados.

4. Evidencias y tabla de impacto requeridas

Para cada fuente se producirán: duplicados_detectados_etapa2.csv (incluye casos candidatos), duplicados_retirados_etapa3.csv (solo retiros confirmados), decision_duplicados_etapa3.csv (grupo, decisión y justificación), impacto_duplicados_etapa3.csv (filas antes, candidatas, retiradas, conservadas, porcentaje) y comprobaciones_etapa3.csv. Si un caso se conserva, debe quedar documentado con su motivo.

5. Precaución respecto a la pregunta de negocio

El indicador central es el número de personas lesionadas por alcaldía y franja horaria. No debe contarse un reporte repetido como una persona adicional, pero tampoco eliminarse una persona distinta sólo porque comparte folio con otra. Antes de cerrar la duplicación, comparar el total de

lesionados por año y alcaldía antes/después, investigar diferencias y documentar las limitaciones de identificación individual.

6. Estado de esta actualización

Decisión metodológica: aprobada para aplicar con revisión. Porcentajes de Etapa 2: calculados con las cifras reportadas. Eliminación efectiva de filas: pendiente de ejecución y comprobación sobre los archivos de la Etapa 3. No se presentan los candidatos como eliminaciones realizadas.