PROYECTO DE

ANÁLISIS DE FRECUENCIA Y SEVERIDAD DE HECHOS DE TRÁNSITO EN LA CDMX

Avance 3. Integración, análisis estadístico y diseño de un ETL reproducible



Repositorio del proyecto:
https://github.com/citlalliruiz31/Proyecto-sobre-Analisis-de-hechos-de-transito-de-la-CDMX

EQUIPO: A&C
INTEGRANTES:
MÉNDEZ CABRAL ÁNGEL DAVID (23-003-1466)
RUIZ MORENO CITLALLI VIVIANA (23-003-1162)
GRUPO: 301
SEMESTRE: 2026-2

UNIVERSIDAD AUTÓNOMA DE LA CIUDAD DE MÉXICO

Inteligencia de Negocios – Semestre 2026-2

AVANCE 03

Integración, análisis descriptivo y diseño de un proceso ETL reproducible

Proyecto: Análisis de accidentes y hechos de tránsito en la Ciudad de México.

Equipo: A&C

Integrantes:

- Mendez Cabral Angel David 23 - 003 - 1466
- Ruiz Moreno Citlalli Viviana 23 - 003 - 1162

Repositorio:
https://github.com/citlalliruiz31/Proyecto-sobre-Analisis-de-hechos-de-transito-de-la-CDMX

1. Introducción

En los avances anteriores desarrollamos la propuesta de nuestro proyecto de Inteligencia de Negocios, enfocado en analizar los accidentes y hechos de tránsito registrados en la Ciudad de México.

Durante el Avance 01 delimitamos el problema, identificamos las fuentes de información y establecimos la importancia de analizar la distribución geográfica y temporal de los hechos de tránsito.

Posteriormente, en el Avance 02 realizamos una exploración de las fuentes de información, revisamos sus estructuras, identificamos problemas de calidad y establecimos reglas para la limpieza y preparación de los datos.

A partir de los resultados obtenidos, identificamos que era necesario establecer un proceso más controlado para preparar la información, ya que las fuentes presentan diferencias en sus estructuras, valores faltantes, registros repetidos, inconsistencias territoriales y diferentes unidades de observación.

Por esta razón, en el Avance 03 continuamos trabajando con las mismas fuentes de información, pero ahora nos enfocamos en implementar las reglas que definimos anteriormente mediante un proceso ETL desarrollado en Python.

Con este proceso buscamos que cada transformación tenga una justificación, que los registros puedan rastrearse y que podamos identificar qué información se conserva, cuál necesita revisión y cuál se excluye del conjunto preparado.

También incorporamos un análisis estadístico descriptivo para comenzar a responder nuestra pregunta de negocio y conocer las características de los registros después de aplicar las reglas de preparación.

2. Pregunta de negocio

Nuestra pregunta principal continúa siendo:

¿En qué alcaldías y franjas horarias de la Ciudad de México se registra la mayor cantidad de personas lesionadas en hechos de tránsito, de acuerdo con los registros disponibles a partir de 2018?

Esta pregunta orienta nuestro trabajo hacia dos dimensiones principales:

- Dimensión geográfica: identificar las alcaldías donde se registra una mayor cantidad de personas lesionadas.
- Dimensión temporal: identificar los años, meses y franjas horarias en los que se concentra una mayor cantidad de personas lesionadas.

La variable principal de interés es la cantidad de personas lesionadas registrada en los hechos de tránsito.

También buscamos distinguir entre la cantidad de accidentes y la cantidad de personas lesionadas, debido a que ambas variables representan situaciones diferentes.

No pretendemos establecer relaciones causales únicamente con estos registros, sino identificar patrones descriptivos que puedan servir como punto de partida para futuros análisis.

3. Objetivos

3.1 Objetivo general

Implementar un proceso ETL reproducible en Python que permita extraer, transformar, validar y preparar las fuentes de información SSC, C5 e INEGI-ATUS, conservando los archivos originales y documentando las decisiones de limpieza, con la finalidad de obtener

conjuntos de datos confiables que permitan analizar la distribución geográfica y temporal de las personas lesionadas en hechos de tránsito en la Ciudad de México.

3.2 Objetivos específicos

1. Retomar las fuentes de información identificadas y analizadas durante los avances anteriores.
2. Aplicar las reglas de calidad, limpieza y preparación previamente establecidas por el equipo.
3. Identificar y separar los registros duplicados exactos, conservando evidencia de los registros retirados.
4. Detectar valores ausentes, inconsistencias y registros que requieren revisión.
5. Aplicar las reglas de validación de edades, incluyendo la separación de registros con edades superiores a 99 años.
6. Revisar los folios repetidos sin eliminarlos automáticamente.
7. Normalizar las variables territoriales y temporales mediante criterios documentados.
8. Generar archivos CSV independientes para registros limpios, pendientes, excluidos y duplicados retirados.
9. Implementar una bitácora automática que registre las operaciones realizadas durante el ETL.
10. Comprobar la conciliación entre los registros iniciales y los diferentes destinos generados.
11. Calcular medidas estadísticas descriptivas para conocer el comportamiento de las variables.
12. Interpretar los resultados obtenidos en relación con nuestra pregunta de negocio.

4. Alcance del Avance 03

En este avance retomamos los resultados y archivos de los avances anteriores.

No sustituimos las fuentes originales ni comenzamos un proyecto diferente. Continuamos trabajando con los conjuntos de datos que fueron identificados y revisados durante el Avance 02.

Las fuentes consideradas son:

Fuente	Función dentro del proyecto
SSC	Fuente principal para analizar hechos de tránsito y personas lesionadas.

C5	Fuente complementaria para revisar reportes e incidentes viales.
INEGI-ATUS	Fuente estadística de referencia para contrastar información.

El periodo de análisis comienza en 2018 y se extiende hasta el último año disponible y validado en cada fuente.

Es importante señalar que no combinamos automáticamente los registros de las tres instituciones, debido a que sus unidades de observación y criterios de captura son diferentes.

Por ejemplo, un registro de C5 no necesariamente representa un accidente confirmado en SSC, y una fila de una tabla de personas no representa lo mismo que una fila de una tabla de hechos.

Por esta razón, cada fuente cuenta con un proceso de preparación independiente.

5. Metodología del proceso ETL

Para este avance implementamos un proceso ETL mediante Python, utilizando principalmente pandas para la manipulación de los datos.

El proceso se divide en cuatro actividades principales:

5.1 Extracción

En esta etapa leemos los archivos originales correspondientes a cada fuente.

Revisamos:

- Nombre del archivo.
- Ubicación.
- Cantidad de registros.
- Cantidad de columnas.
- Tipos de datos.
- Nombres de variables.
- Periodo cubierto.
- Valores faltantes.
- Identificadores disponibles.

También conservamos los archivos originales sin modificarlos, ya que necesitamos mantener una referencia para comparar los resultados antes y después del procesamiento.

5.2 Transformación

En esta etapa aplicamos las reglas de preparación definidas anteriormente.

Entre las operaciones consideradas se encuentran:

- Normalización controlada de nombres de columnas.
- Conversión de variables numéricas.
- Revisión de fechas y horas.
- Identificación de valores faltantes.
- Detección de duplicados exactos.
- Revisión de folios repetidos.
- Validación de edades.
- Revisión de inconsistencias territoriales.
- Creación de variables derivadas.
- Clasificación de registros según su estado.

Cada transformación debe conservar la información original cuando sea necesario para permitir la trazabilidad.

5.3 Validación

Después de aplicar las transformaciones realizamos comprobaciones para verificar que los datos cumplan las reglas establecidas.

No consideramos suficiente que el código termine sin errores. También necesitamos comprobar que los resultados tengan sentido y que las operaciones no hayan provocado pérdidas injustificadas de información.

Por ello revisamos:

- Tipos de datos.
- Rangos permitidos.
- Fechas y horas válidas.
- Categorías reconocidas.
- Registros duplicados.
- Folios repetidos.
- Valores pendientes.
- Cantidades de registros antes y después de cada operación.

5.4 Preparación y generación de archivos

Finalmente, separamos los registros de acuerdo con su resultado de validación.

No guardamos todos los registros en un único archivo, porque necesitamos demostrar qué ocurrió con cada uno.

La estructura de salidas contempla:

Archivo	Contenido
`*_limpio.csv`	Registros que cumplen las reglas para el análisis.
`*_pendientes.csv`	Registros que necesitan revisión adicional.
`*_excluidos_por_regla.csv`	Registros que no cumplen una regla de inclusión.
`*_duplicados_exactos_retirados.csv`	Copias adicionales retiradas del conjunto limpio.
`*_folios_repetidos_revision.csv`	Registros con folios repetidos que necesitan revisión.
`conciliacion_por_archivo.csv`	Comprobación del destino de los registros.
`bitacora.csv`	Registro automático de las operaciones del ETL.

6. Aplicación de las reglas de calidad

Para realizar la preparación de los datos retomamos el documento de reglas desarrollado por el equipo.

Estas reglas no se establecieron de manera improvisada durante el procesamiento, sino que fueron definidas previamente a partir de los problemas identificados durante el análisis exploratorio.

6.1 Conservación de los archivos originales

No modificamos directamente los archivos originales.

Cada proceso trabaja sobre una copia independiente, lo que permite comparar los registros de entrada con los resultados obtenidos.

Esta decisión es importante porque, si encontramos un problema durante la limpieza, podemos regresar a la fuente original y revisar el registro.

6.2 Conservación de las variables originales

No sobrescribimos directamente las columnas originales cuando realizamos conversiones o normalizaciones.

En su lugar, generamos columnas auxiliares.

Por ejemplo, cuando necesitamos convertir una variable de edad a un formato numérico, conservamos el valor recibido y trabajamos con una nueva columna para realizar las validaciones.

De esta manera podemos identificar si el problema se encontraba en el dato original o en el proceso de conversión.

6.3 Identificación de valores ausentes

Durante el análisis distinguimos entre:

- Valores nulos.
- Cadenas vacías.
- Categorías como SD.
- Valores numéricos iguales a cero.

Esta distinción es importante porque un cero puede representar un valor real y no necesariamente información faltante.

Por ello evitamos sustituir automáticamente los valores ausentes por cero, media o mediana.

Cuando un registro no cuenta con información suficiente para una validación, lo clasificamos como pendiente cuando corresponde.

6.4 Identificación de duplicados exactos

Una de las operaciones importantes del proceso consiste en identificar registros duplicados.

Para nuestro proyecto consideramos duplicado exacto únicamente cuando coinciden todos los valores de las columnas originales evaluadas para la tabla correspondiente.

Cuando encontramos copias adicionales idénticas, retiramos las copias del conjunto limpio, pero conservamos la evidencia en un archivo independiente.

Esto permite evitar el doble conteo sin perder la posibilidad de revisar los registros originales.

Es importante distinguir estos casos de los folios repetidos, ya que compartir un mismo identificador no significa necesariamente que dos filas representen la misma observación.

6.5 Tratamiento de folios repetidos

Los folios repetidos se revisan de manera independiente.

No los eliminamos automáticamente porque pueden representar diferentes personas, vehículos o registros relacionados con un mismo incidente.

Por ejemplo, un mismo hecho de tránsito puede estar relacionado con más de una persona lesionada.

Eliminar todas las filas que comparten un folio podría provocar la pérdida de información importante.

Por esta razón, los registros que requieren revisión se conservan en archivos independientes.

6.6 Validación de edades

Una de nuestras reglas particulares corresponde a la revisión de edades en los registros de personas.

Establecimos que las edades superiores a 99 años no se utilizarán en los cálculos que requieren una edad válida.

Esto no significa que eliminemos silenciosamente los registros.

Cuando identificamos una edad superior a 99:

1. Conservamos el registro original.
2. Identificamos el valor de edad.
3. Aplicamos la regla establecida.
4. Separamos el registro en un archivo independiente.
5. Registramos el motivo de exclusión.
6. Evitamos que participe en los cálculos estadísticos de edad.

De esta manera podemos justificar por qué el registro no forma parte del conjunto limpio.

También revisamos las edades negativas, vacías y no numéricas, debido a que requieren un tratamiento diferente.

La regla de edad mayor a 99 no implica que eliminemos el hecho de tránsito completo. Se aparta el registro de persona de los análisis que requieren una edad válida, sin afectar automáticamente otras tablas o conteos.

6.7 Normalización territorial

Durante la revisión identificamos que los nombres de alcaldías pueden presentar diferencias de escritura.

Por ello realizamos una revisión de los valores territoriales y establecemos equivalencias únicamente cuando podemos justificarlas.

Conservamos el valor original y generamos una variable normalizada.

Cuando no podemos identificar correctamente una equivalencia, el registro queda pendiente de revisión.

No asignamos una alcaldía por suposición.

6.8 Validación temporal

Para responder nuestra pregunta de negocio utilizamos principalmente la hora de ocurrencia del incidente.

No sustituimos esta variable por la hora de creación o registro del reporte.

Esta decisión es importante porque ambas representan momentos diferentes.

Para facilitar el análisis agrupamos las horas válidas en cuatro franjas:

Franja	Horario
Madrugada	00:00 a 05:59
Mañana	06:00 a 11:59
Tarde	12:00 a 17:59
Noche	18:00 a 23:59

Los registros sin una hora de ocurrencia válida no se asignan artificialmente a una franja.

7. Clasificación y destino de los registros

Uno de los objetivos principales de este avance es poder explicar qué sucedió con cada registro después de aplicar las reglas.

Por ello establecemos cuatro destinos principales:

Registros conservados: cumplen las condiciones necesarias para formar parte del conjunto preparado.

Registros pendientes: necesitan una revisión adicional porque presentan información incompleta, contradictoria o que no podemos validar con los criterios disponibles.

Registros excluidos: no cumplen una regla previamente establecida para formar parte del conjunto analítico.

Duplicados exactos retirados: corresponden a copias adicionales idénticas que se retiraron del conjunto limpio para evitar el doble conteo.

La comprobación general que utilizamos es:

$$N_{inicial} = N_{conservados} + N_{pendientes} + N_{excluidos} + N_{duplicados}$$

Los folios repetidos se consideran una categoría de revisión y no se suman nuevamente, porque pueden coincidir con registros ya clasificados.

Esta comprobación nos permite demostrar que no estamos perdiendo registros sin explicación.

8. Bitácora automática del proceso ETL

Para documentar las operaciones realizadas adaptamos la función `anotar()` de la Nota 11.

La finalidad de esta función es registrar automáticamente las actividades importantes del proceso.

La bitácora debe incluir los siguientes campos:

Campo	Descripción
fecha	Fecha y hora de ejecución.
archivo	Archivo procesado.
paso	Operación realizada.
filas_antes	Cantidad de registros antes de la operación.
filas_despues	Cantidad de registros después de la operación.
detalle	Descripción de la actividad.
responsable	Integrante responsable.
regla	Regla aplicada.
resultado	Resultado de la operación.
observaciones	Problemas o comentarios adicionales.

La bitácora permite consultar qué operaciones se realizaron, cuántos registros se modificaron o separaron y qué reglas justificaron cada decisión.

Además, facilita la revisión del proceso cuando necesitamos identificar en qué etapa ocurrió algún problema.

Es importante señalar que la bitácora automática y la bitácora del equipo cumplen funciones diferentes.

La primera registra las operaciones del código, mientras que la segunda documenta las actividades, responsables y evidencias del trabajo.

9. Análisis estadístico descriptivo

Después de preparar los datos realizamos un análisis estadístico para conocer mejor su comportamiento.

Seleccionamos medidas que permiten describir la distribución de los datos y que pueden relacionarse con nuestra pregunta de negocio.

9.1 Media

La media permite conocer el promedio de una variable numérica.

La utilizamos cuando la unidad de observación y el significado de la variable permiten calcular un promedio válido.

Por ejemplo, podemos utilizarla para describir el promedio de personas lesionadas por hecho de tránsito, siempre que contemos con un campo o una relación validada que permita calcularlo.

9.2 Mediana

La mediana representa el valor central de una distribución ordenada.

La incluimos porque los datos pueden presentar valores extremos que influyan considerablemente en la media.

Al comparar ambas medidas podemos identificar si la distribución se encuentra concentrada en valores bajos o si presenta observaciones elevadas.

9.3 Moda

La moda identifica el valor que aparece con mayor frecuencia.

Nos permite reconocer cuál es el valor más común dentro de una variable.

Su interpretación dependerá de la variable que estemos analizando.

9.4 Cuartiles

Los cuartiles dividen los datos ordenados en cuatro partes.

Utilizamos:

- Q1: primer cuartil.
- Q2: segundo cuartil o mediana.
- Q3: tercer cuartil.

Estas medidas permiten comprender cómo se distribuyen los valores y qué proporción de observaciones se concentra en determinados intervalos.

9.5 Desviación estándar

La desviación estándar permite conocer qué tanto se dispersan los datos respecto a su media.

Un valor elevado indica mayor variabilidad, mientras que un valor bajo indica que las observaciones se encuentran más concentradas alrededor del promedio.

9.6 Diagramas de caja y bigotes

También utilizamos diagramas de caja y bigotes para visualizar la distribución de las variables numéricas.

Estos gráficos permiten identificar:

- Mediana.
- Primer cuartil.
- Tercer cuartil.
- Rango intercuartílico.
- Posibles valores atípicos.

No eliminamos automáticamente los valores que aparecen fuera de los bigotes, ya que primero debemos revisar si corresponden a observaciones válidas.

Importante: las medidas estadísticas se calcularán sobre las variables y unidades de observación correspondientes. No se deben calcular promedios de identificadores, folios o códigos categóricos como si fueran cantidades.

10. Resultados del proceso ETL

Esta sección se completará con los resultados reales de la ejecución de los cinco notebooks.

Para evitar presentar cantidades incorrectas, registraremos los resultados directamente desde los CSV generados.

Fuente	Registros iniciales	Conservados	Pendientes	Excluidos	Duplicados retirados
SSC	Por completar	Por completar	Por completar	Por completar	Por completar
C5	Por completar	Por completar	Por completar	Por completar	Por completar
INEGI-ATUS	Por completar	Por completar	Por completar	Por completar	Por completar

Los resultados se presentarán por archivo y tabla, respetando las diferencias entre sus unidades de observación.

También incluiremos las evidencias de las edades separadas por la regla de 99 años, los duplicados exactos retirados y los registros pendientes de revisión.

11. Resultados del análisis estadístico

Una vez ejecutados los análisis, presentaremos los resultados de la siguiente manera:

Análisis	Resultado obtenido	Interpretación
Alcaldía con mayor cantidad de lesionados	Por completar	Identificar la concentración territorial.
Franja horaria con mayor cantidad	Por completar	Identificar la concentración temporal.
Media	Por completar	Interpretar el promedio.

Mediana	Por completar	Interpretar el valor central.
Moda	Por completar	Identificar el valor más frecuente.
Cuartiles y dispersión	Por completar	Interpretar la variabilidad.

Con estos resultados podremos comenzar a contestar nuestra pregunta de negocio.

No obstante, las conclusiones se limitarán a los registros disponibles y validados. No afirmaremos que una alcaldía sea más peligrosa que otra únicamente porque tenga una mayor cantidad de registros, ya que también sería necesario considerar factores como población, movilidad y exposición vial.

12. Limitaciones identificadas

Durante el desarrollo del proyecto reconocemos algunas limitaciones que debemos considerar al interpretar los resultados.

1. Las fuentes de información presentan diferentes estructuras y unidades de observación.
2. Los registros de C5 no necesariamente representan accidentes confirmados.
3. Los folios repetidos no pueden considerarse automáticamente duplicados.
4. Existen registros con información territorial que necesita revisión.
5. Algunos registros presentan valores ausentes o inconsistentes.
6. Los códigos horarios de INEGI-ATUS requieren interpretarse con sus catálogos.
7. No todas las fuentes cuentan necesariamente con la misma cobertura temporal.
8. Los resultados descriptivos no permiten establecer relaciones causales.

Estas limitaciones no impiden desarrollar el proyecto, pero sí determinan hasta dónde podemos interpretar los resultados.

13. Reproducibilidad y organización del repositorio

Para mantener organizado el proyecto proponemos la siguiente estructura:

Proyecto-Inteligencia-de-Negocios/
│

```
├── Docs/
│   ├── Avance01/
│   ├── Avance02/
│   ├── Avance03/
│   │   ├── Informe_Avance03.docx
│   │   ├── Documento_Reglas.pdf
│   │   └── Evidencias/
│   │
│   ├── Diccionario_Datos/
│   └── Fuentes/
│
├── Datos/
│   ├── SSC/
│   ├── C5/
│   └── INEGI_ATUS/
│
├── Notebooks3/
│   └── Avance03/
│       ├── 01_ETL_SSC_Avance03.ipynb
│       ├── 02_ETL_C5_Avance03.ipynb
│       ├── 03_ETL_INEGI_ATUS_Avance03.ipynb
│       ├── 04_Analisis_Exploratorio_Avance03.ipynb
│       └── 05_Preparacion_PostgreSQL_Avance03.ipynb
│
├── SQL/
│
├── PowerBI/
│
└── Resultados/
    ├── SSC/
    ├── C5/
    ├── INEGI_ATUS/
    ├── Analisis/
    └── Bitacoras/
```

La reproducibilidad se comprobará ejecutando nuevamente los notebooks desde los archivos originales y verificando que se obtengan los mismos resultados con las mismas entradas y reglas.

14. Conclusiones

En este tercer avance continuamos desarrollando nuestro proyecto de Inteligencia de Negocios mediante la implementación de un proceso ETL reproducible.

A diferencia del avance anterior, en el que nos concentramos principalmente en explorar las fuentes e identificar problemas de calidad, ahora buscamos aplicar las reglas que establecimos para preparar los datos de una manera controlada.

Consideramos importante conservar los registros originales y generar archivos independientes para los datos limpios, pendientes, excluidos y duplicados exactos retirados. Esto nos permite justificar las decisiones tomadas y evitar que la limpieza provoque una pérdida de información sin explicación.

También incorporamos la generación de una bitácora automática para registrar las operaciones realizadas, las cantidades de registros procesados y las reglas aplicadas.

Finalmente, el análisis estadístico nos permitirá conocer la distribución de los datos y comenzar a identificar las alcaldías y franjas horarias donde se concentra una mayor cantidad de personas lesionadas.

Con este avance buscamos establecer una base de datos preparada, documentada y verificable que pueda utilizarse posteriormente para continuar con la integración en PostgreSQL y la construcción de los análisis y visualizaciones en Power BI.