

Análisis de frecuencia y severidad de hechos de tránsito en la CDMX

Méndez Cabral Ángel David · Ruiz Moreno Citlalli Viviana · Grupo 301

- ☐ No presentamos resultados definitivos: dejamos una propuesta viable, trazable y reproducible para el resto del semestre.

El problema y la decisión que buscamos apoyar

1

Contexto

Ejercicio académico simulado con datos abiertos del Gobierno de la CDMX; no es un encargo real de la SSC ni del C5.

2

Problema

2018 - 2023: **134,079 hechos, 155,989 lesionados y 2,608 fallecidos** reportados; los totales no distinguen alcaldía, día, horario ni tipo de evento.

3

Decisión

Identificar y priorizar alcaldías y periodos para análisis posteriores y posibles acciones preventivas. El análisis **organiza y compara**; no decide la acción.

Pregunta de negocio y alcance

¿En qué alcaldías y horarios de la CDMX se concentra la mayor frecuencia de hechos de tránsito y en cuáles se observa mayor severidad registrada, considerando lesionados y fallecidos?

Alcance definido

- **Precisión:** Eliminamos "riesgo": más hechos no implica mayor probabilidad sin exposición.
- **Periodo SSC:** 2018-01-01 a 2023-12-31; C5 como referencia: 2018-11-15 a 2024-02-29.
- **Unidad territorial:** Alcaldía (principal); colonia (secundaria).

Fuera de alcance

- Causas específicas de los hechos
- Aforo o medida de exposición vial
- Jurisdicciones fuera de la CDMX

Fuentes revisadas: por qué SSC es la fuente principal

Fuente	Rol	Unidad de observación	Cobertura	Decisión
SSC	Principal	Un hecho de tránsito	CDMX, 2018 - 2023	Aceptada
C5	Complementaria	Un incidente vial reportado	Archivos 2018 - 2024	Con cautela; no se suma
INEGI-ATUS	Referencia estadística	Accidente registrado	Nacional	Referencia
Kaggle (1997 - 2022)	Referencia documental	Accidente del dataset	México, deriva de ATUS	Cautela; verificar licencia

❏ **SSC:** CSV 134,079×26 (27 MB) + 3 tablas de víctimas (24 - 31 MB c/u), licencia CC-BY-4.0-ESP. No sumamos C5 y SSC: representan universos distintos.

Evidencia de los datos crudos: qué recibimos

Archivo	Filas × columnas	Unidad de observación	Cobertura
Hechos de tránsito (SSC)	134,079 × 26	Un hecho de tránsito	2018 - 2023
Víctimas por sexo (SSC)	144,044 × 24	Una persona	2018 - 2023
Víctimas por edad (SSC)	158,077 × 23	Una persona	2018 - 2023
Víctimas por tipo (SSC)	107,795 × 24	Una persona	2020 - 2023
Incidentes viales C5	590,636 + 504,261 × 17	Un incidente reportado	2018 - 2024

Las tablas de víctimas tienen más filas que la de hechos porque un mismo hecho puede afectar a varias personas; se relacionan por folio.

Evidencia de los datos crudos: problemas visibles

Folios "SD"

7,288 registros (5.4%) dificultan vincular hechos con víctimas.

Folios repetidos

219 folios afectan 7,825 filas.

Edades imposibles

14 registros de víctimas con edades entre 302 y 523 años.

Alcaldía inconsistente

"GUSTAVO A MADERO" y "GUSTAVO A. MADERO" son categorías distintas; "AV INSURGENTES" no es alcaldía válida: 18 valores en vez de 16.

Nulos relevantes

unidad_a_cargo ~49%, clasificación de vialidad/origen/sentido ~26%, matrícula de unidad médica ~61%, hora_evento ~3.7%.

Cobertura parcial

Tipo de persona solo desde 2020; no permite perfilar 2018 - 2019.

❏ Estos hallazgos no invalidan la fuente: definen las reglas de ETL que documentaremos.

Plan analítico preliminar

Necesidad analítica	Dimensiones	Medida base	Métrica preliminar
Priorizar alcaldías	Alcaldía, colonia, fecha, tipo	Conteo de hechos	Hechos por alcaldía y año
Priorizar horarios y días	Hora, día	Conteo de hechos	Densidad por día/hora, bloques horarios
Medir severidad	Tipo de evento, alcaldía, horario	Lesionados y fallecidos	Fallecimientos por cada 1,000 accidentes; % con lesionados
Perfilar víctimas	Sexo, edad, tipo de persona	Conteo por condición	Distribución de víctimas por perfil

Preguntas secundarias: ¿Qué alcaldías y colonias concentran más frecuencia? ¿Qué tipos de evento tienen más fallecimientos por 1,000 accidentes? ¿Qué perfil aparece en los hechos más severos? ¿Cómo se comportan frecuencia y severidad 2018 - 2023?

Arquitectura propuesta del flujo BI

Una cadena reproducible: cada etapa deja evidencia trazable desde el archivo crudo hasta la visualización.

Siete etapas, de los datos crudos a la decisión

Etapa	Entrada	Qué haremos	Salida
Datos crudos	CSV SSC, víctimas, C5	Conservar sin alterar; registrar origen y licencia	data/raw/ e inventario
Python	Archivos crudos	Perfilar nulos, duplicados, rangos, categorías	Notebooks y gráficas exploratorias
ETL	Reglas documentadas	Homologar alcaldías, tratar folios SD, validar edades	Datos limpios y bitácora
PostgreSQL	Datos preparados	Modelar hechos y tablas relacionadas	Esquema y registros de carga
SQL analítico	Tablas almacenadas	Calcular frecuencia y severidad	Consultas y vistas reutilizables
Power BI	Vistas analíticas	Modelo semántico, mapas, tarjetas	Tablero trazable
Decisión	Resultados interpretados	Reconocer alcaldías y horarios prioritarios	Criterio de priorización con límites explícitos

Viabilidad, riesgos y próximos pasos

Riesgos y cómo los atenderemos

- **Folios SD (5.4%):** Excluir del cruce; mantener en agregados.
- **Folios repetidos:** Revisar significado antes del modelado.
- **Edades fuera de rango:** Definir rango válido en el perfilamiento.
- **Alcaldía inconsistente:** Homologar contra catálogo oficial.
- **SSC y C5, universos distintos:** Mantener las fuentes separadas.
- **Frecuencia ≠ riesgo:** No concluir "mayor riesgo" sin exposición.

Conclusión

La propuesta es viable como proyecto de BI: la pregunta puede responderse de forma descriptiva con las variables disponibles en SSC.

Próximos pasos

1. Perfilar en Python
2. Documentar reglas de ETL
3. Modelar en PostgreSQL
4. Construir consultas SQL
5. Desarrollar tablero en Power BI